

目录

1. Getting Started	2
1.1. 课程简介	2
1.2. 期中考试	2
1.3. 人工智能发展阶段	2
2. 数学基础	5
2.1. 回归(Regression)	5
2.2. 概率论	5
3. 机器学习	7
3.1. 什么是机器学习?	7
3.2. 大数据时代的到来	7
3.3. 机器学习的直观理解	7
3.4. 机器学习的典型应用	7
3.5. 机器学习的局限性	8
3.6. 任务、经验、表现	8
3.7. 机器学习的任务	8
3.8. 机器学习的经验	9
3.9. 机器学习的表现	9
3.10. 机器学习 vs. 优化	10
3.11. 机器学习 vs. 统计	10
3.12. 小结	10
4. 线性模型	10
4.1. 线性模型的基本思想	10
4.2. 线性模型的任务类型	11
4.3. 线性回归	11
4.4. 线性回归的矩阵形式	12
4.5. 线性回归的闭式解	12
4.6. 梯度下降	13
4.7. 正则化思想	13
4.8. 从贝叶斯观点理解正则化	13
4.9. Ridge 回归	13
4.10. Lasso 回归	14
4.11. L_1 与 L_2 正则化的比较	14
4.12. 广义线性模型的思想	15
4.13. 逻辑回归	15
4.14. 实践流程：以房价预测为例	15
5. 本节总结	16
5.1. 机器学习部分	16
5.2. 线性模型部分	16
6. 思考题	16

第一讲

——总体介绍——

1. Getting Started

1.1. 课程简介

- 搜索算法
- 强化学习初步
- AI 系统
- 大模型与具身智能
- 课程安排：基础+机器学习+深度学习（神经网络，卷积神经网络等）+强化学习+大模型+具身智能+AI 系统
- 四个平行班，作业进度持平

1.2. 期中考试

时间：20260430

1.3. 人工智能发展阶段

1.3.1. 人工智能之初

起源

图灵：(1948) 人造的机器能够表现出像人一样的智能行为。

- 通过模仿人类大脑的**奖励、惩罚**教育机制来训练机器学习。
- 无组织机器 **unorganized machine**：模拟婴儿的大脑皮层。
- 初期并没有尝试把人工智能做成人的形状，而仅仅是模仿人类的智能行为。（受限于计算机的大小等）

图灵测试

1950 年，图灵提出了图灵测试：如果一个机器能够在文本交流中让人类无法区分它和另一个人，那么这个机器就可以被认为具有智能。

目标：测试机器是不是达到了“智能”的水平。

是否通过了图灵测试？甚至超越人类水平？

达特茅斯会议：首次使用“人工智能 (*Artificial Intelligence*)”这个术语

1.3.2. 人工智能的早期时代（百花齐放的春天）

- 逻辑理论证明
- 下棋机器人
- 对话程序 (ELIZA)

逻辑理论家

1956 年，Newell 和 Simon 开发了逻辑理论家 (Logic Theorist)，这是第一个人工智能程序。它能够证明数学定理，展示了机器可以进行复杂的推理。

- 首个自动推理的程序
- 首个人工智能的程序
- Information Processing Language (IPL)：第一种专门为人工智能设计的编程语言。

得出的结论：人类问题的根本是搜索的过程

第一次机器翻译（1953-54）：俄文翻译成英文。

感知机

计算机视觉最早期的任务：识别图像中的物体。1957 年，Frank Rosenblatt 发明了感知机（Perceptron），这是一个简单的神经网络模型，能够进行二分类任务。

一台专门的机器：Mark I Perceptron，能够识别简单的图像模式。

单层神经网络解决字母 C 的识别问题。

影响：被认为成功模拟人脑。

1.3.3. 中期：符号主义的繁荣

1) 自动定理的证明

- 定理机器证明是指通过计算机程序自动完成数学定理的推理与验证，亦称自动定理证明（ATP），包含广义和狭义两种范畴：前者通过机器有限步推断完成证明（如四色定理验证），后者需建立统一程序证明特定数学命题。该领域源于 17 世纪莱布尼茨的符号逻辑构想，属数学与人工智能交叉学科，主要技术路线包括代数方法、前推/后推搜索法等。1956 年纽厄尔、肖和西蒙开发的逻辑理论机首次实现自动推理，1959 年杰勒恩特团队研制出可解几何题的证明机。
- 中国数学家吴文俊创立平面几何定理机器证明的代数消元法（吴方法），1984 年该方法验证了 130 个几何定理。20 世纪 80 年代后，研究重点转向自动推理方向。¹

2) 专家系统：Dendral, Mycin², XCON

- Dendral 是由斯坦福大学开发的一个专家系统，专门用于分析化学质谱数据。它能够识别有机化合物的结构，极大地提高了化学家分析数据的效率。
- MYCIN 是由美国斯坦福大学研制的用于细菌感染患者诊断和治疗的专家系统。MYCIN 系统于 1972 年开始建造，1978 年最终完成，用 INTER LISP 语言编写。MYCIN 知识库有二百多条规则，可识别 51 种病菌，正确处理 23 种抗生素。MYCIN 对于专家系统的发展有着重要的影响，被人们视为专家系统的设计规范，现在的专家系统大多都是参考 MYCIN 而设计研发的基于规则的专家系统。总体来说，MYCIN 系统的应用领域非常广泛，涉及到社会、经济和服务领域。³
- XCON（eXpert CONfigurer）是由美国卡内基梅隆大学开发的一个专家系统，专门用于配置计算机系统。它能够根据用户的需求和约束条件，自动生成计算机系统的配置方案，极大地提高了计算机系统设计的效率。

3) 大百科全书 Cyc(encyclopedia of common sense knowledge)

- Cyc 是由美国人工智能公司 Cyc Corporation 开发的一个大型知识库，旨在收集和组织人类常识知识。Cyc 包含了数百万条事实和规则，涵盖了各种领域的知识，如物理、社会、文化等。Cyc 的目标是使计算机能够理解和推理人类常识，从而更好地与人类进行交互。⁴

4) IBM Watson

- IBM Watson 是由 IBM 开发的一个人工智能系统，最初是为了参加美国电视节目《危险边缘》(Jeopardy!) 而设计的。⁵Watson 能够理解自然语言，分析大量数据，并进行推理和决策。在 2011 年，Watson 成功击败了两位人类冠军，展示了其强大的自然语言处理和知识推理能力。此后，Watson 被应用于医疗、金融等领域，帮助专业人士进行诊断和决策。

5) 日本五代机（1978）

- 终极目标：知识信息处理，专家系统以及自然语言的理解。

¹第一版有误。

²课件上打印的 Myclin，应该是笔误

³详细见 <https://zhuanlan.zhihu.com/p/580745886>，本段落摘自此文。

⁴现在的人工智能并没那么强调规则，而是更偏向于大数据。未来或许应该是双线并行的模式。

⁵这是一款知识竞赛，这款 IBM Watson 战胜了人类并获得 100 万奖金。

- 五代机的衰落：1981 年的会议记录只有 280 页，但是 1988 年有了 1300 页，说明五代机的研究过于庞杂，缺乏核心问题的聚焦。很多八竿子打不着的问题也被划进五代机的研究。1994 年，五代机项目被日本政府正式终止。

1.3.4. 近期：连接主义的昌盛

关于神经网络的研究

- 2012 年，深度学习算法在 ImageNet 图像识别竞赛中取得了突破性的成绩，标志着深度学习的兴起。（图像识别）卷积神经网络系统
- 2016 年，AlphaGo 击败了世界围棋冠军李世石，展示了深度学习在复杂策略游戏中的强大能力。（下棋机器人）
 - ▶ 围棋的复杂性远高于国际象棋，因为围棋的棋盘更大，可能的棋局更多。AlphaGo 使用了深度神经网络和蒙特卡洛树搜索算法，能够评估棋盘状态并预测对手的下一步，从而在比赛中取得了胜利。
 - ▶ 有监督学习阶段：AlphaGo 通过学习大量的专业棋谱，训练了一个策略网络，能够预测专业棋手的下一步棋。
 - ▶ 强化学习阶段：AlphaGo 通过与自己对弈，进一步优化了策略网络，形成了一个更强大的强化学习网络。
- **自进化**：不断通过自我对弈来提升自己的棋艺水平。
- 2022 年，OpenAI 发布 ChatGPT。（自然语言对话）
 - ▶ 大模型：指模型的参数量很大，通常在数十亿甚至数千亿级别。大模型能够捕捉更多的语言特征和上下文信息，从而在自然语言处理任务中表现出色。
 - ▶ 机器学习的本质：Data $\rightarrow$ Knowledge 的过程。Data 包括 $(x_1, x_2, \dots, x_n)$ ，其中每个 x_i 代表一个特征，Knowledge 是指另一组数据 $(y_1, y_2, \dots, y_m)$ ，其中每个 y_j 代表一个标签或输出。希望寻找一个函数 $f(x)$ 从而将输入的内容输出为我们想要的结果，即 $f(x_i) = y_i$ 。大模型指参数量很大，能够更好地拟合数据，从而在自然语言处理任务中表现出色。
 - ▶ ChatGPT 的弱点：数学和逻辑能力较弱，容易产生幻觉（hallucination），即生成不准确或虚假的信息。
- 大模型的要求：**涌现能力**。当模型的规模和训练参数达到一定的阈值时，模型的性能和泛化能力突然会出现显著提升，这种现象称为大模型的涌现现象。“涌现能力”可谓是大模型的神来之笔：这些能力在小规模模型中不存在，而仅在大规模模型中存在。
 - ▶ 但是视觉模型到目前为止还没有出现涌现能力。
- 多模态大模型：能够处理和理解多种类型数据（如文本、图像、音频等）的模型。例如，OpenAI 的 CLIP 模型能够同时处理文本和图像数据，从而实现跨模态的理解和生成。
 - ▶ 这也是无奈之举：由于视觉模态还没有“大模型”，因而借用语言大模型改造使用。
- AIGC（AI Generated Content）时代的到来：随着大模型不断发展，AI 生成内容（AIGC）已经成为一个重要的趋势。AIGC 指的是由人工智能生成的各种类型的内容，如文本、图像、音频等。这些内容可以用于娱乐、教育、营销等多个领域，极大地丰富了人们的创作和表达方式。
 - ▶ Sora, NanoBanana 等。

第二讲

——数学基础——

2. 数学基础

2.1. 回归(Regression)

$x \rightarrow y$ 的一个映射

问题定义：在一组数据点中，找到一个多项式函数，尽可能拟合数据分布的趋势(Ristribution)。

如何评判拟合效果？

差异函数（误差函数）：⁶

$$f(x, w) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M$$

$$E(w) = \frac{1}{2N} \sum_{i=1}^N (y_i - f(x_i, w))^2$$

M 的数值越大，模型容量(capacity)越大，拟合能力越强，但过拟合(overfitting)的风险也越大。

过拟合：Overfitting 只是拟合了绝大多数点，但是并不能很好的表现数据的趋势，在其他数据测试中表现得很差。这种情况的特点是 M 特别大，模型过于复杂，拟合了训练数据中的噪声，而不是数据的真实趋势。

欠拟合：Underfitting 是指模型在训练数据上表现不好，无法捕捉数据的趋势。这通常是因为模型过于简单，无法拟合训练数据。

过拟合的解决方法：增加数据量，权重正则化。

2.2. 概率论

2.2.1. 概率的定义

频率学派：一个事件的概率是该事件发生次数占总试验次数的比例

贝叶斯学派：概率是表达个人或主观信念的不确定性的度量

联合概率：事件 $X = X_i$ 与事件 $Y = Y_j$ 同时发生的概率，记为 $p(X = X_i, Y = Y_j)$

加和规则（全概率公式）：

$$p(X) = \sum_{i=1}^n p(X|Y = Y_i)p(Y = Y_i)$$

贝叶斯定理：

$$p(X|Y) = \frac{p(X|Y)p(Y)}{\sum_Y p(X|Y)p(Y)} \propto p(X|Y)p(Y)$$

$p(Y|X)$ ：后验概率(posterior)：当观察到 X 的结果之后的概率。

$p(X|Y)$ ：似然(likelihood)：在给定 Y 的条件下， X 发生的概率，它表达了对于参数 y 的不同设置，观测到的数据集有多大的可能性。

⁶误差函数与课件的形式不符合，我们认为课件的公式需要乘以 $\frac{1}{N}$ 才是合理的，前面的系数 $\frac{1}{2}$ 的解释是为了求一阶导数系数方便计算。

$p(Y)$: 先验概率(prior): 在观察到数据之前的概率, 我们对 y 的猜测。

独立事件: 两个事件相互独立, 意味着一个事件的发生不影响另一个事件发生的概率。即

$$p(X, Y) = p(X)p(Y),$$

$$p(X) = p(X|Y), p(Y) = p(Y|X).$$

$p(x)$: 概率密度函数(probability density function), 它描述了连续随机变量在某个特定值附近取值的概率密度。对于连续随机变量, 概率密度函数的积分在某个区间内给出了该区间内随机变量取值的概率。

$P(x)$: 累积分布函数(cumulative distribution function), 它描述了随机变量取值小于或等于某个特定值的概率。对于连续随机变量, 累积分布函数是概率密度函数的积分。

关系: $P(x) = \int_{-\infty}^x p(x) dx$

数学期望: $\mathbb{E}(x) = \sum p(x) \cdot x$

方差: 描述数据的离散程度。

协方差: $Cov(x, y) = E_{x,y}(x - \mathbb{E}(x))(y - \mathbb{E}(y)) = E_{x,y} - \mathbb{E}(x)\mathbb{E}(y)$

高斯分布/正态分布: $p(x) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$

2.2.2. 频率学派: 最大似然估计(MLE)

例子: 某个班级的智商服从正态分布 $N(\mu, \sigma^2)$, 那么 μ, σ 是等待估计的参数, 从这个班随机抽取五个人, 测得他们的智商数值, 分别是 x_1, x_2, x_3, x_4, x_5 , 那么我们可以通过最大似然估计来估计 μ 和 σ 的值。最大似然估计是指, 在给定观测数据的情况下, 选择使得观测数据出现的概率最大的参数值。

2.2.3. 贝叶斯学派: 最大后验概率

最大后验概率(MAP)估计是指, 在给定观测数据的情况下, 选择使得参数的后验概率最大的参数值。与最大似然估计不同, 最大后验概率估计还考虑了先验概率, 即在观察到数据之前对参数的猜测。

第三讲

——机器学习介绍与线性模型——

3. 机器学习

3.1. 什么是机器学习？

定义：机器学习是指算法的设计与分析，使得模型能够**基于经验**，在**某些任务**上，其**表现**不断提升。

也就是说，机器学习的三个核心元素是：

- **任务 (Task)**：我们希望模型完成什么事情；
- **经验 (Experience)**：模型可利用的数据或历史样本；
- **表现 (Performance)**：衡量模型做得好不好的标准。

机器学习的本质可以概括为：

数据 → 学习算法 → 知识/预测规则

或者说，是一个“从数据到知识”的过程。

3.2. 大数据时代的到来

随着互联网、社交网络、传感器、移动设备等的发展，数据量爆炸式增长。课件中指出，人类每天产生的数据量可达到：

$$2.5 \times 10^{18}$$

字节级别的数据为机器学习提供了丰富的“经验”，也推动了从数据中自动提取规律的需求。

因此，机器学习成为连接“**数据**”与“**知识**”的重要工具。

3.3. 机器学习的直观理解

人类学习和机器学习有相似之处：

- 人类通过观察大量例子积累经验；
- 机器通过训练数据学习规律；
- 最终都形成某种“判断能力”或“预测能力”。

例如：

- 看到许多猫和狗的图片后，学会区分“猫”与“狗”；
- 阅读很多文本后，学会判断一篇文章属于体育、新闻还是科技；
- 观察历史房价后，学会预测未来房价。

3.4. 机器学习的典型应用

机器学习已经广泛应用于许多场景中，例如：

- 图片分类；
- 文档分类；
- 垃圾邮件过滤；
- 股市预测；
- 语音识别；
- 自然语言处理；

- 计算机视觉；
- 机器人；
- 医疗图像分析；
- 计算生物学；
- 社交网络分析等。

近年来，机器学习也掀起了新一轮 AI 热潮，例如大语言模型、自动驾驶、生成式 AI 等。

3.5. 机器学习的局限性

尽管机器学习取得了巨大成功，但距离真正像人类一样智能仍有较大差距。

当前机器学习系统通常仍然：

- 难以自动适应开放世界中的新场景；
- 难以识别训练中从未见过的新种类；
- 容易依赖训练数据分布，泛化能力有限。

因此，机器学习还有很长的路要走。

3.6. 任务、经验、表现

前面提到，理解机器学习可以抓住三个关键词：

- **任务**；
- **经验**；
- **表现**。

下面分别展开说明。

3.7. 机器学习的任务

机器学习的任务可以分为以下几类：

- **有监督学习**；
- **无监督学习**；
- **半监督学习**；
- **弱监督学习**；
- **强化学习**。

3.7.1. 有监督学习

有监督学习中，训练数据包含输入和标签，即：

给定 $x \in \mathcal{X}$ ，学习预测 $y \in \mathcal{Y}$

其中：

- x 表示输入数据；
- y 表示标签或目标值。

根据标签类型不同，有监督学习又可分为：

- **分类问题**：标签离散；
- **回归问题**：标签连续。

分类问题 示例：

- 图片分类：猫 / 狗；
- 文档分类：体育 / 科技 / 新闻；

- 垃圾邮件识别：Spam / Not Spam；
- 医疗图像诊断：正常 / 异常。

回归问题 示例：

- 房价预测；
- 销量预测；
- 气温预测；
- 股票价格预测。

3.7.2. 无监督学习

无监督学习中，训练数据只有输入，没有标签，即：

给定 $x \in \mathcal{X}$ ，在没有 y 的情况下学习数据中的结构

无监督学习可理解为“没有老师的学习”或“自己教自己学习”。

典型任务包括：

- **密度估计**：估计数据分布；
- **聚类**：将相似的数据聚到一起；
- **降维**：用更少的变量表示原始数据。

聚类 的目标是把相似样本划分为同一组。**降维** 的目标是从高维数据中提取低维表示，便于可视化、压缩或后续学习。

3.7.3. 其他学习范式

除了监督学习和无监督学习，还有：

- **半监督学习**：少量有标签数据 + 大量无标签数据；
- **弱监督学习**：标签不精确、不完整或含噪声；
- **强化学习**：智能体通过与环境交互，根据奖励信号学习策略。

3.8. 机器学习的经验

在机器学习中，经验通常由**训练数据**提供。

需要区分：

- **训练数据 (training data)**：用于学习模型；
- **测试数据 (test data)**：用于评估模型在新样本上的表现。

一个好的机器学习算法应当：

- 不会对训练数据发生**过拟合 (overfit)**；
- 能够对测试数据良好**泛化 (generalize)**。

也就是说，模型不仅要“记住”训练样本，更要学到背后的规律。

3.9. 机器学习的表现

机器学习中的“表现”通常通过**损失函数 (loss function)** 或评价指标衡量。

设真实标签为 Y ，模型预测为 $f(X)$ ，则表现可用它们之间的接近程度衡量。

常见例子：

- **二分类**中，可用 $\frac{0}{1}$ 损失：
$$\text{loss}(Y, f(X)) = 1_{f(X) \neq Y}$$

- 回归中，常用平方损失：
 $\text{loss}(Y, f(X)) = (f(X) - Y)^2$
- 密度估计中，常用负对数似然损失。

因此，机器学习的目标通常可以表述为：

寻找一个预测函数 f ，使得平均损失尽可能小

3.10. 机器学习 vs. 优化

从数学角度看，机器学习通常表现为一个优化问题。

理想目标是寻找预测规则 f ，使其在整体数据分布上最优，即最小化期望风险：

$$f^* = \arg \min_f \mathbb{E}_{X,Y} [\text{loss}(Y, f(X))]$$

但是，真实数据分布通常未知，因此无法直接优化期望风险。于是我们使用训练数据上的经验风险来近似：

$$\hat{f}_n = \arg \min_f \left(\frac{1}{n} \right) \sum_{i=1}^n \text{loss}(y_i, f(x_i))$$

这体现了机器学习与优化的关系：

- 优化提供求解工具；
- 机器学习关注如何从有限数据中学到可泛化的规律。

3.11. 机器学习 vs. 统计

机器学习与统计学关系密切。

二者都关心如何从数据中推断规律，但机器学习更强调：

- 预测性能；
- 算法设计；
- 大规模计算；
- 泛化能力。

因此，机器学习不只是简单的曲线拟合，而是要构建适用于未来测试数据的预测规则。

3.12. 小结

本部分主要介绍了：

- 机器学习的定义；
- 三个基本元素：任务、经验、表现；
- 常见学习范式；
- 训练/测试数据、过拟合与泛化；
- 机器学习与优化、统计之间的联系。

4. 线性模型

4.1. 线性模型的基本思想

线性模型是机器学习中最基础、最重要的一类模型。

其核心思想是：通过输入特征的线性组合来预测输出。

设输入特征为 $x = (x_1, x_2, \dots, x_p)$ ，则线性模型写为：

$$f(x) = w^T x + b = w_1 x_1 + w_2 x_2 + \dots + w_p x_p + b$$

其中：

- $w = (w_1, w_2, \dots, w_p)$ 为权重参数；
- b 为偏置项；
- w, b 都是需要通过数据学习得到的模型参数。

例如在房价预测中，输入特征可以包括：

- 建造年份；
- 房屋面积；
- 楼层数；
- 房屋质量评分；
- 卧室数量等。

线性模型会为每个特征分配一个权重，再将它们加权求和得到预测值。

4.2. 线性模型的任务类型

线性模型可以用于两类基本任务：

- **线性回归**：预测连续数值；
- **线性分类**：预测离散类别。

例如：

- 房价预测属于回归问题；
- 股票涨跌判断属于分类问题。

4.3. 线性回归

4.3.1. 线性回归模型

给定数据集

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

线性回归希望学习一个模型：

$$f(x_i) = w^T x_i + b$$

使得预测值 $f(x_i)$ 尽可能接近真实值 y_i 。

4.3.2. 目标函数

线性回归中最常用的目标函数是**最小二乘 (least squares)**，即最小化平方误差和：

$$(w^*, b^*) = \arg \min_{w, b} \left(\frac{1}{n} \right) \sum_{i=1}^n (y_i - w^T x_i - b)^2$$

这就是**最小二乘估计**。

选择平方损失的原因包括：

- 数学形式简单；
- 对大误差惩罚更强；
- 通常可以得到良好的解析性质。

4.3.3. 经验风险与大数定理

理想情况下，我们想最小化总体上的期望平方误差：

$$f^* = \arg \min_f \mathbb{E}[(f(X) - Y)^2]$$

但真实分布未知，因此用样本均值近似期望：

$$\hat{f}_n = \arg \min_f \left(\frac{1}{n} \right) \sum_{i=1}^n (f(x_i) - y_i)^2$$

这背后依赖大数定理：当样本数足够大时，样本平均会逼近期望。

4.4. 线性回归的矩阵形式

为方便表达，把参数和数据写成矩阵形式。

令

$$\beta = [w_1, w_2, \dots, w_p, b]^T$$

并构造设计矩阵 A ，则目标函数可写为：

$$\hat{\beta} = \arg \min_{\beta} \left(\frac{1}{n} \right) (A\beta - Y)^T (A\beta - Y)$$

其中：

- A 是 $n \times p$ 或扩展后的设计矩阵；
- Y 是标签向量；
- β 是待估计参数向量。

这样可以把回归问题统一成标准的二次优化问题。

4.5. 线性回归的闭式解

4.5.1. 正规方程

对目标函数求导并令其为零，可得到正规方程：

$$A^T A \hat{\beta} = A^T Y$$

若 $A^T A$ 可逆，则可得到闭式解：

$$\hat{\beta} = (A^T A)^{-1} A^T Y$$

这就是线性回归的解析解。

4.5.2. 闭式解存在的条件

闭式解存在的关键条件是 $A^T A$ 可逆。这通常要求：

- 特征之间线性无关；
- 设计矩阵满列秩。

特别地，当样本数 $n < p$ 时，通常有：

$$\text{rank}(A^T A) \leq \min(n, p) < p$$

因此 $A^T A$ 不可逆，闭式解不存在。

此外，即使理论上可逆，当特征维度很高时，直接求逆在计算上也会非常昂贵。

4.6. 梯度下降

当闭式解不存在，或者矩阵求逆计算代价过大时，可以将线性回归作为优化问题，用**梯度下降**（**gradient descent**）求解。

设目标函数为：

$$J(\beta) = (A\beta - Y)^T(A\beta - Y)$$

由于这是一个凸函数，因此可沿梯度负方向迭代更新参数：

$$\beta^{t+1} = \beta^t - \alpha \nabla J(\beta^t)$$

其中：

- β^t 为第 t 次迭代的参数；
- α 为步长（学习率）；
- $\nabla J(\beta^t)$ 为当前梯度。

4.6.1. 步长的影响

步长 α 的取值对收敛效果有重要影响：

- α 过大：收敛快，但可能震荡甚至发散；
- α 过小：收敛稳定，但速度较慢。

因此需要合理选择学习率。

4.7. 正则化思想

当特征维度高、样本较少，或者特征之间存在相关性时，普通最小二乘容易出现：

- $A^T A$ 不可逆；
- 模型参数过大；
- 过拟合。

为了解决这些问题，可以在目标函数中加入**正则化项**（**regularization term**）。

正则化的思想是：

- 在拟合训练数据的同时；
- 对模型复杂度加以约束；
- 从而提高泛化能力。

4.8. 从贝叶斯观点理解正则化

从贝叶斯观点看，可以为参数 β 引入先验分布，然后做 MAP（最大后验估计）：

$$\hat{\beta}_{\text{MAP}} = \arg \max_{\beta} \log p(D | \beta) + \log p(\beta)$$

其中：

- $\log p(D | \beta)$ 是似然项；
- $\log p(\beta)$ 是先验项。

不同先验会对应不同形式的正则化。

4.9. Ridge 回归

若对参数引入高斯先验：

$$\beta \sim \mathcal{N}(0, \tau^2 I)$$

则 MAP 估计等价于求解：

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i^T \beta)^2 + \lambda \|\beta\|_2^2$$

这就是 **Ridge Regression**（岭回归）。

其中 $\|\beta\|_2^2$ 是 L_2 正则项。

4.9.1. Ridge 回归的特点

- 惩罚较大的参数；
- 使参数整体变小、更平滑；
- 通常不会把参数精确压到 0；
- 可缓解共线性问题；
- 对应解为：

$$\hat{\beta} = (A^T A + \lambda I)^{-1} A^T Y$$

由于加入了 λI ，矩阵更容易可逆，因此能解决普通最小二乘不可逆的问题。

4.10. Lasso 回归

若对参数引入拉普拉斯先验：

$$p(\beta) \propto e^{-|\beta|}$$

则 MAP 估计等价于：

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i^T \beta)^2 + \lambda \|\beta\|_1$$

这就是 **Lasso Regression**。

其中 $\|\beta\|_1$ 是 L_1 正则项。

4.10.1. Lasso 回归的特点

- 能产生**稀疏解**；
- 即很多参数会被直接压缩为 0；
- 相当于自动进行特征选择；
- 在高维问题中尤其有用。

4.11. L_1 与 L_2 正则化的比较

4.11.1. L_2 正则化

L_2 正则化对应圆形约束集，倾向于让所有参数都较小，但通常不会产生很多精确的 0。

优点：

- 解稳定；
- 数值上容易处理；
- 对共线性较鲁棒。

4.11.2. L_1 正则化

L_1 正则化对应菱形约束集，最优解更容易落在坐标轴上，因此容易得到稀疏解。

优点：

- 自动进行特征选择；
- 降低模型存储和计算成本；
- 适合高维稀疏问题。

4.11.3. 对比总结

- **Ridge**：参数变小，但通常不为 0；
- **Lasso**：容易得到稀疏解，部分参数直接为 0。

4.12. 广义线性模型的思想

线性模型虽然简单，但形式非常灵活。

例如，对输出取对数，可得到 **log-linear regression**：

$$\log y = w^T x + b$$

进一步地，可以考虑一个单调可微函数 $g(\cdot)$ ，构造更一般的模型：

$$y = g^{-1}(w^T x + b)$$

这就是广义线性模型的基本思想。

它说明：

- 线性模型不一定只能直接预测 y ；
- 也可以先对线性组合进行非线性变换，再得到输出。

4.13. 逻辑回归

在线性模型中，分类问题常见的模型是**逻辑回归（logistic regression）**。

其形式是在 $w^T x + b$ 外层加上 Sigmoid 函数：

$$f_{w,b}(x) = \sigma(w^T x + b)$$

其中：

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

逻辑回归输出的是一个介于 0 和 1 之间的概率，因此适合二分类问题。

虽然名字叫“回归”，但它本质上是一个分类模型。

4.14. 实践流程：以房价预测为例

实际机器学习任务通常包括以下步骤：

- 1) **问题形式化**：明确预测目标；
- 2) **数据获取**：收集历史房屋信息及售价；
- 3) **数据预处理**：清洗数据、构造特征；
- 4) **建模与调参**：训练模型并选择超参数；
- 5) **系统部署**：将模型用于在线预测；
- 6) **持续维护**：监控效果，用新数据更新模型。

这说明机器学习不仅仅是“选一个模型”，而是一个完整的工程流程。

5. 本节总结

本节课主要介绍了机器学习和线性模型的基本概念。

5.1. 机器学习部分

- 机器学习是基于经验提升任务表现的算法设计与分析；
- 三个核心要素是：任务、经验、表现；
- 机器学习可分为有监督学习、无监督学习、半监督学习、弱监督学习和强化学习；
- 好的模型应避免过拟合，并具有良好的泛化能力；
- 机器学习与优化、统计密切相关。

5.2. 线性模型部分

- 线性模型通过特征的线性组合进行预测；
- 线性回归用于连续值预测；
- 最小二乘是线性回归的经典目标函数；
- 当 $A^T A$ 可逆时，线性回归有闭式解；
- 当不可逆或维度过高时，可用梯度下降或正则化方法；
- Ridge 使用 L_2 正则，Lasso 使用 L_1 正则；
- Lasso 更容易产生稀疏解；
- 广义线性模型与逻辑回归扩展了线性模型的应用范围。

6. 思考题

- 机器学习的三个基本元素分别是什么？
- 有监督学习与无监督学习的区别是什么？
- 什么是过拟合？什么是泛化？
- 线性模型的基本形式是什么？
- 线性回归为什么常采用平方损失？
- 线性回归何时存在闭式解？
- Ridge 与 Lasso 的差别是什么？
- 为什么说 Lasso 具有特征选择作用？
- 逻辑回归为什么属于分类模型？